

Диагностика ишемической болезни сердца по медицинским показателям:

сравнение классических алгоритмов и нейронной сети

1. Постановка задачи и данные

Решается задача бинарной классификации: определить наличие ишемической болезни сердца (ИБС) у пациента по результатам неинвазивных и малоинвазивных обследований — анамнеза, ЭКГ покоя, нагрузочного теста и биохимии крови.

Практический смысл в том, что золотой стандарт диагностики — коронарная ангиография — процедура инвазивная, дорогая и сопряжённая с риском; модель на дешёвых показателях позволяет приоритизировать пациентов для направления на неё. Использован датасет Heart Disease (Cleveland Clinic Foundation) из репозитория UCI: 303 пациента, 13 признаков. Исходная целевая переменная (степень сужения артерий от 0 до 4) бинаризована стандартным образом: 0 — здоров, 1–4 — есть ИБС. Классы распределены как 164 здоровых (54,1 %) и 139 больных (45,9 %), то есть дисбаланс незначителен.

1.1. Выбор метрики

Ключевая особенность медицинской постановки — несимметричность цены ошибок. Ложноотрицательный результат (больной отправлен домой как здоровый) несёт риск инфаркта и потенциально фатального исхода, ложноположительный (здоровый направлен на ангиографию) — финансовые издержки и небольшой процедурный риск. Общепринятая экспертная оценка соотношения — от 5 : 1 до 10 : 1. Поэтому доля правильных ответов (ассигасу) как основная метрика не подходит: она неявно предполагает равную цену ошибок. Единой метрикой для всех сравнений выбран ROC-AUC — он не зависит от порога и корректно работает при умеренном дисбалансе; отдельно анализируются чувствительность и специфичность при рабочем пороге (раздел 6).

1.2. Методология валидации

Единая для всего исследования схема, применённая ко всем без исключения моделям:


- стратифицированная кросс-валидация по 5 фолдам (StratifiedKFold, shuffle=True, random_state=42);
- единая метрика ROC-AUC для всех сравнений;

- вся предобработка (импутация пропусков, масштабирование, one-hot кодирование) помещена внутрь sklearn Pipeline и обучается заново на обучающей части каждого фолда;
- отложенная тестовая выборка (61 пациент, 20 %) не участвовала ни в подборе гиперпараметров, ни в отборе признаков, ни в выборе порога и была использована один раз, на финальном этапе.


Последний пункт принципиален: любое решение, принятое на основании данных, является частью процедуры обучения — включая статистики масштабирования, заполнение пропусков, отбор признаков и порог классификации. Нарушение даёт утечку данных и оптимистично смещённую оценку.

2. Разведочный анализ и предобработка данных


Датасет содержит 6 строк с пропусками (2 %) в признаках `sa` и `thal`. Учитывая малый объём данных, строки не удалялись: импутация медианой и модой выполняется внутри Pipeline, то есть статистики считаются только по обучающей части каждого фолда. Анализ выбросов по правилу полутора межквартильных размахов выявил экстремальные значения холестерина (до 564 мг/дл) и давления (до 200 мм рт. ст.); все они физиологически возможны, а доля больных среди них заметно отличается от базовой — это сигнал, а не шум. Выбросы сохранены: для линейных моделей и сети их влияние снижается стандартизацией, деревья к ним нечувствительны по построению.



Числовые признаки в разрезе диагноза



Распределения признаков






Рисунок 1. Распределение классов, распределения признаков, корреляционная матрица и боксплоты числовых признаков по классам

Основные наблюдения по результатам разведочного анализа:

1. Максимальная достигнутая ЧСС (thalach) — сильнейший числовой предиктор, причём в обратную сторону: у больных ИБС она ниже. Это соответствует физиологии нагрузочного теста — ишемия ограничивает способность миокарда наращивать частоту.
2. Признаки oldpeak и slope описывают одно явление — поведение сегмента ST при нагрузке. Клинически опасна не любая депрессия ST, а глубокая депрессия в сочетании с плоским или нисходящим наклоном.
3. Категория cp = 4 (бессимптомное течение) оказалась самой «больной»: таких пациентов направляют на ангиографию по совокупности других факторов риска, то есть это заведомо отобранная группа. Сильной мультиколлинеарности нет — максимальные попарные корреляции около 0,4 по модулю, поэтому регуляризация нужна для контроля переобучения, а не вырожденности матрицы.

2.1. Конструирование признаков

На основе наблюдений выше сконструировано пять признаков. Все формулы детерминированы и вычисляются построчно, не используя статистик по выборке, поэтому применимы до разбиения без риска утечки.

Признак	Формула	Обоснование
hr_reserve	$\text{thalach} / (220 - \text{age})$	Доля от возрастного максимума ЧСС. Абсолютное значение несравнимо между пациентами разного возраста.
st_burden	$\text{oldpeak} \times \text{slope}$	Взаимодействие глубины депрессии ST и её наклона — то, что линейная модель не может выразить сама.
chol_age_ratio	chol / age	Холестерин растёт с возрастом; отношение отвечает на вопрос «высокий ли он для своего возраста».
bp_age_ratio	$\text{trestbps} / \text{age}$	Та же логика для артериального давления.
n_risk_factors	сумма 4 бинарных флагов	Аддитивная шкала классических факторов риска по образцу шкал Framingham и SCORE.

Таблица 1. Сконструированные признаки и их клиническое обоснование

После предобработки размерность составила 23 признака. Номинальные `cp`, `restecg`, `slope` и `thal` кодируются one-hot, поскольку их числовые коды не несут порядка: тип боли «4» не больше типа «1». Признак `sa` оставлен порядковым — это счётчик поражённых сосудов.

3. Проверка полезности сконструированных признаков

Клиническое обоснование признака не гарантирует его полезности для модели, поэтому проведено прямое сравнение (ablation study): одна и та же модель, одна и та же схема кросс-валидации, единственное отличие — состав признаков. Чтобы вывод не зависел от одной удачной модели, эксперимент повторён для представителей трёх семейств. Дополнительно проверен вариант без признаков `sa` и `thal`, получаемых дорогими процедурами.

Набор признаков	LogReg	Random Forest	Gradient Boosting
A. Только исходные признаки	0,909	0,888	0,865
B. Исходные + сконструированные	0,904	0,867	0,854
C. Вариант B без <code>sa</code> и <code>thal</code> (скрининг)	0,848	0,811	0,798

Таблица 2. Ablation study: CV ROC-AUC при разном составе признаков. Медианное стандартное отклонение по фолдам — 0,032

Результат отрицательный: конструирование признаков не улучшило качество, а слегка ухудшило его — для всех трёх семейств моделей. Величина потери (от 0,005 до 0,021) сопоставима со стандартным отклонением по фолдам, то есть формально находится в пределах шума, однако знак одинаков во всех трёх случаях, что уже не похоже на случайность.

Объяснение согласуется с общей темой работы: ограничением служит объём выборки. Каждый добавленный признак повышает размерность пространства, в котором модель ищет решение по 242 объектам, и увеличивает дисперсию оценок коэффициентов, тогда как новой информации почти не добавляется — `hr_reserve` есть детерминированная функция `thalach` и `age`, `chol_age_ratio` — функция `chol` и `age`, а модель с обоими аргументами способна восстановить их отношение сама. Независимым методом это подтверждает и анализ важности (раздел 6.2): из пяти сконструированных признаков заметный вклад даёт только `st_burden`, выражающий мультипликативное взаимодействие, то есть ровно то, чего линейная модель построить не может.

Напротив, отказ от признаков `sa` и `thal` обходится вдвое дороже — потеря составляет от 0,055 до 0,057 ROC-AUC и заведомо выходит за пределы шума. Два признака, полученных флюороскопией и сцинтиграфией с таллием, несут непропорционально много информации о целевой переменной. При этом «скрининговый» вариант C, будучи слабее по метрике, представляет самостоятельную практическую ценность: он применим там, где дорогие процедуры недоступны, и сравнивать его с полной моделью по ROC-AUC методологически некорректно — у них разные сценарии использования.

4. Классические модели машинного обучения

Обучено 13 базовых алгоритмов из шести семейств: линейные (логистическая регрессия с L1- и L2-регуляризацией), метрические (kNN, SVM с RBF-ядром), вероятностные (наивный байес), деревья решений, бэггинг-ансамбли (Random Forest, Extra Trees, AdaBoost) и градиентный бустинг (GradientBoosting, XGBoost, LightGBM, CatBoost). Принципом отбора служило разнообразие: модели разных семейств делают разные предположения о данных, что важно и само по себе, и для последующего ансамблирования.

Для четырёх представителей семейств выполнен подбор гиперпараметров перебором по сетке с той же схемой кросс-валидации. Сетки намеренно компактны: чем больше конфигураций перебирается на малой выборке, тем сильнее оптимистичное смещение лучшего результата.

4.1. Вложенная кросс-валидация

Величина этого смещения измерена напрямую. Вложенная схема разделяет две задачи: внутренний цикл (4 фолда) выбирает гиперпараметры, внешний (5 фолдов) оценивает качество процедуры целиком, включая внутренний выбор. Среднее смещение составило +0,011 ROC-AUC — ровно на столько отчёт вида «по результатам GridSearch получено AUC = X»

переоценивает реальное качество. Все финальные выводы работы опираются на вложенную оценку и отложенный тест, а не на лучший результат внутренней кросс-валидации.

5. Нейронная сеть (многослойный персептрон)

Сеть реализована на PyTorch (nn.Module, BCEWithLogitsLoss, оптимизатор Adam) и обернута в интерфейс, совместимый со scikit-learn. Это позволило прогнать её через ту же процедуру оценки, что и классические модели — тот же Pipeline, та же схема кросс-валидации, та же метрика, — что делает сравнение корректным.

5.1. Обоснование архитектуры

Отправная точка — соотношение числа параметров и объектов: для сети $23 \rightarrow 32 \rightarrow 16 \rightarrow 1$ это 1313 параметров при 242 обучающих объектах, то есть впятеро больше параметров, чем наблюдений. Без регуляризации такая сеть выучит выборку наизусть.

Принятые решения: ReLU в скрытых слоях (её производная при положительном аргументе равна единице против максимума 0,25 у сигмоиды, что устраняет затухание градиента); выход — один логит без активации в паре с BCEWithLogitsLoss, численно устойчивее связки Sigmoid и BCELoss; размер батча 32. Гипотезы проверены экспериментально: перебор по сетке «глубина $\times$ ширина» (для ускорения — на 3 фолдах, поэтому абсолютные значения не сопоставимы с таблицей 5) показал, что оптимум лежит в области малых сетей — лучший результат у одного слоя из 8 нейронов (201 параметр, CV ROC-AUC 0,891), худший 0,845. Разброс по сетке (0,046) сопоставим с разбросом по фолдам, поэтому отдельные ячейки различать нельзя, но тенденция однозначна: рост числа параметров в десятки раз качества не улучшает.




Рисунок 2. Тепловая карта «глубина $\times$ ширина»: качество и число параметров


Тезис о превосходстве глубоких узких сетей над мелкими широкими при равном числе параметров здесь значимо не подтверждается: 3 слоя по 16 нейронов дают 0,884 против 0,879 у одного слоя из 64 — разница внутри шума. Преимущество глубины реализуется на задачах с иерархической структурой признаков, где низкоуровневые представления собираются в высокоуровневые; здесь же каждый из 23 табличных признаков уже является осмысленной клинической величиной, и иерархию строить не из чего.

5.2. Кривые обучения и регуляризация

Кривые обучения показывают классическую картину переобучения. Без регуляризации ROC-AUC на обучении достигает 1,000 при 0,862 на валидации (разрыв 0,138), минимум функции потерь — на 33-й эпохе. С регуляризацией разрыв сокращается до 0,118 (0,997 против 0,879), а минимум смещается на 70-ю эпоху.

При этом валидационный ROC-AUC остаётся почти плоским, тогда как функция потерь заметно ухудшается: сеть теряет калибровку вероятностей раньше, чем ранжирующую способность. Для медицинской задачи различие существенно — врачу нужна не только сортировка пациентов по риску, но и осмысленная величина вероятности.

Кривые обучения MLP






Рисунок 3. Кривые обучения MLP: функция потерь и ROC-AUC на train/validation по эпохам, с регуляризацией и без, а также сравнение методов регуляризации

Конфигурация регуляризации	CV ROC-AUC	Train AUC	Overfit gap
Dropout 0,3 + BatchNorm + Weight Decay	0,845	0,995	0,150
Dropout 0,3	0,836	0,985	0,149
Без регуляризации	0,809	0,997	0,188
Weight Decay 1e-3	0,808	0,997	0,189
BatchNorm	0,795	1,000	0,205

Таблица 3. Сравнение методов регуляризации MLP (архитектура 32 → 16, 200 эпох)

Разрыв между лучшей конфигурацией и сетью без регуляризации составляет 0,036 ROC-AUC и превышает стандартное отклонение по фолдам — одно из немногих сравнений в работе, где различие выходит за пределы шума. Отдельного комментария заслуживает BatchNorm: сам по себе он даёт худший результат (0,795 — ниже, чем вообще без регуляризации), но в комбинации с Dropout и weight decay входит в лучшую конфигурацию. Причина в масштабе задачи: среднее и дисперсия оцениваются по батчу из 32 объектов и потому сами шумны, а при 242 объектах этот шум не успевает усредниться. Технически метод здесь на грани применимости — при неполном последнем батче из одного пациента дисперсию вычислить невозможно и обучение прерывается ошибкой. Это пример того, что рекомендации «по умолчанию» привязаны к масштабу задачи, для которого выведены.

При этом даже у лучшей конфигурации ROC-AUC на обучении близок к единице при 0,845 на валидации: регуляризация смягчает переобучение, но не устраняет его, поскольку ограничением остаётся объём выборки. Показательно, что финальная модель с архитектурой из одного слоя и ранней остановкой дала 0,892 против 0,845 у сети 32 → 16 — сокращение ёмкости и своевременная остановка оказались действеннее выбора метода регуляризации.

6. Ансамблирование, интерпретация и выбор порога

6.1. Стекинг и блендинг

Реализованы четыре мета-модели стекинга и пять стратегий блендинга (простое усреднение, взвешивание по качеству, оптимизация весов методом SLSQP и дифференциальной эволюцией, ранговое усреднение). Мета-признаки собраны из out-of-fold предсказаний: для каждого объекта берётся предсказание модели, которая при обучении его не видела. Качество каждой стратегии оценено вложенной кросс-валидацией.

Ни один из девяти ансамблей не превзошёл лучшую одиночную модель. Лучший результат — стекинг с логистической регрессией в качестве мета-модели, 0,903 против 0,906 у настроенной логистической регрессии.

Причина видна из диагностики: средняя попарная корреляция предсказаний шести отобранных моделей составляет 0,936 — все они улавливают один и тот же сигнал и ошибаются на одних и тех же пациентах, а ансамбль усредняет ошибки только тогда, когда они независимы. Показательно и то, что простое усреднение (0,895) не уступает оптимизации весов методом SLSQP (0,895): у усреднения ноль подбираемых параметров и оно не может переобучиться. Единственная область, где ансамблирование дало выигрыш, — калибровка вероятностей: логарифмическая функция потерь у стекинга с Random Forest равна 0,256 против 0,282–0,294 у одиночных логистических регрессий, что для медицинской задачи существенно третьего знака ROC-AUC. Контраст с плохо калиброванными моделями разителен: у наивного байеса логарифмическая потеря 3,82, у решающего дерева 2,13 при ROC-AUC около 0,85 — они сносно ранжируют пациентов, но выдают абсурдно переуверенные вероятности.


6.2. Интерпретация модели

Использованы два независимых подхода: permutation importance (падение ROC-AUC при перемешивании признака, 50 повторов на тесте) и SHAP, раскладывающий каждое отдельное предсказание на аддитивные вклады признаков. Permutation importance вычислен для финальной логистической регрессии, SHAP — для ExtraTrees, поскольку TreeExplainer точен и быстр на древесных моделях. То, что две модели разных семейств дают согласованный рейтинг, делает вывод устойчивее.

Рейтинг по permutation importance (в скобках — падение ROC-AUC при перемешивании признака): са, число поражённых сосудов (0,088); ср, тип боли в груди (0,039); st_burden (0,018); slope (0,013); thal, таллиевый тест (0,013); далее exang, trestbps, sex, thalach и hr_reserve со значениями от 0,009 до 0,004.

Ранжирование клинически осмысленно: модель опирается на число поражённых сосудов, тип боли в груди, результат таллиевого теста и показатели нагрузочного теста — то есть ровно на те признаки, которые кардиолог использует при оценке риска. Совпадение с врачебной логикой является более весомым аргументом в пользу доверия к модели, чем сама по себе высокая метрика: оно означает, что модель не эксплуатирует случайные артефакты данных.

Признаки `chol_age_ratio`, `bp_age_ratio` и `n_risk_factors` имеют важность, равную нулю, что согласуется с отрицательным результатом ablation study из раздела 3 и подтверждает его независимым методом.







Рисунок 4. SHAP: диаграмма beeswarm и разбор предсказаний для двух пациентов с крайними оценками риска

6.3. Выбор рабочего порога

Все метрики выше вычислены при пороге 0,5 — значении по умолчанию, не имеющем клинического обоснования. Рассмотрены три критерия: максимум F1-меры, максимум индекса Юдена и минимум ожидаемых издержек при соотношении цен 10 : 1. Порог подбирался на out-of-fold предсказаниях обучающей выборки: выбор порога — это решение по данным, и подбор его на тесте дал бы смещённую оценку.

Порог	Чувствительность	Специфичность	FN	FP	Издержки
0,50 (по умолчанию)	0,893	0,848	3	5	35
0,42 (max F1 и индекс Юдена)	0,964	0,818	1	6	16
0,12 (минимум издержек)	1,000	0,485	0	17	17

Таблица 4. Результаты на отложенном тесте при разных порогах. Издержки = $10 \times FN + 1 \times FP$

Снижение порога с 0,50 до 0,12 сокращает число пропущенных больных с трёх до нуля ценой роста ложных тревог с пяти до семнадцати. Доля правильных ответов при этом падает с 0,869 до 0,721 — и это не деградация модели, а прямое следствие того, что ассигасу предполагает равную цену ошибок, которой в данной задаче нет.

Показательно, что на тесте порог 0,42 дал издержки 16 против 17 у порога 0,12, то есть оказался незначительно выгоднее, хотя подбирался по другому критерию. Это следствие малого размера теста: 61 пациента недостаточно, чтобы порог, оптимальный на обучающих данных, гарантированно оставался оптимальным. Практическая рекомендация — выбирать порог в диапазоне 0,12–0,42 совместно с клиницистами, исходя из доступности ангиографии в конкретном учреждении.

7. Сводное сравнение моделей

Всего обучено и оценено 28 моделей по единой схеме. Ниже — десять представительных позиций; четыре близких по качеству варианта блендинга опущены, полная таблица содержится в ноутбуке и файле final_comparison.csv.

Ранг	Модель	Семейство	CV ROC-AUC	$\pm$ std	Test AUC	Время, с
1	LogReg (tuned)	Линейные	0,906	0,021	0,957	0,03
2	LogReg (L1)	Линейные	0,906	0,017	0,957	0,07
3	LogReg (L2)	Линейные	0,904	0,024	0,961	0,10
4	Stacking (LogReg)	Ансамбль	0,903	0,018	0,967	0,01
6	Blending (Diff. Evolution)	Ансамбль	0,902	0,016	0,964	5,09

Ранг	Модель	Семейство	CV ROC-AUC	$\pm$ std	Test AUC	Время, с
7	Stacking (RandomForest)	Ансамбль	0,900	0,022	0,969	0,53
8	ExtraTrees	Ансамбли	0,897	0,025	0,967	0,50
13	MLP (PyTorch)	Нейросети	0,892	0,034	0,948	1,94
14	SVM (tuned)	Метрические	0,890	0,028	0,963	0,03
16	RandomForest (tuned)	Ансамбли	0,886	0,027	0,978	0,69

Таблица 5. Избранные модели из 28 по результатам кросс-валидации

7.1. Переобучение по семействам моделей

Убедительнее самого рейтинга выглядит средний разрыв между качеством на обучении и на валидации: он выстроен строго в порядке ёмкости моделей.

Семейство	Моделей	Лучший CV ROC-AUC	Средний overfit gap
Линейные	3	0,906	0,027
Вероятностные	1	0,861	0,026
Метрические	3	0,890	0,059
Ансамбли (бэггинг)	4	0,897	0,102
Нейросети	2	0,892	0,123
Бустинг	5	0,883	0,124
Деревья	1	0,765	0,190

Таблица 6. Качество и степень переобучения по семействам моделей

Зависимость практически монотонна: чем выше ёмкость модели, тем больше она выучивает обучающую выборку, не улучшая обобщение. У логистической регрессии разрыв 0,027, у бустингов 0,124, у одиночного решающего дерева 0,190 — и оно же последнее в общем рейтинге.

7.2. Почему нельзя выбирать модель по тестовой выборке

Отдельного разбора заслуживает расхождение между кросс-валидацией и тестом. У 27 моделей из 28 ROC-AUC на тесте оказался выше, чем на кросс-валидации (в среднем 0,955 против 0,876), а ранговая корреляция между двумя оценками составляет всего 0,29 — то есть порядок моделей по тесту почти не совпадает с порядком по кросс-валидации.

Наиболее яркий случай — RandomForest (tuned): 16-е место по кросс-валидации (0,886) и первое по тесту (0,978). Если бы финальная модель выбиралась по тестовой метрике, победителем была бы объявлена модель из середины рейтинга.

Объяснение не связано с ошибкой в коде: тест — это 61 пациент, один случайный срез, и оценка по нему имеет большую дисперсию, тогда как кросс-валидация усредняет пять разбиений. Именно поэтому все решения принимались по кросс-валидации, а тест использовался однократно. Соблазн «проверить на тесте и выбрать лучшее» — та же утечка данных, только на уровне выбора модели. Отсюда же следует ограничение на интерпретацию различий: медианное стандартное отклонение по фолдам равно 0,022, а разрыв между первым и тринадцатым местом — всего 0,014, и парный t-критерий не выявил значимых различий ни в одной из 15 пар среди топ-моделей.

8. Выводы

8.1. Какая модель победила и почему

Первые три места заняли логистические регрессии (0,906, 0,906 и 0,904), опередив градиентный бустинг, случайный лес, нейронную сеть и все ансамбли. Финальная модель — логистическая регрессия с L1-регуляризацией, $C = 1,52$: CV ROC-AUC $0,906 \pm 0,021$, ROC-AUC на тесте 0,957, время обучения 0,03 с.

Причины такого исхода:

1. Объём данных: 242 обучающих объекта на 23 признака. Модели высокой ёмкости имеют низкое смещение, но их разброс на такой выборке съедает весь выигрыш. Это видно и внутри семейства нейросетей: MLP с контролем ёмкости даёт 0,892, а избыточная сеть $128 \rightarrow 64$ без регуляризации — 0,800.
2. Природа зависимости: медицинские факторы риска связаны с исходом преимущественно монотонно (чем больше поражённых сосудов, чем глубже депрессия ST, чем ниже хронотропный резерв, тем выше вероятность заболевания). Логит такой зависимости хорошо приближается линейной функцией.
3. Отсутствие иерархии признаков: преимущество глубоких сетей состоит в построении иерархии представлений, тогда как здесь каждый из 23 признаков уже является осмысленной клинической величиной.

Необходима оговорка о значимости: разрыв между первым местом и тринадцатым, где расположился MLP, составляет 0,014 при медианном стандартном отклонении по фолдам 0,022, и парный t-критерий не выявил значимых различий. Корректная формулировка: на этих данных сложные модели не дают преимуществ, а не «линейная модель статистически превосходит нейронную сеть». При этом разброс MLP по фолдам (0,034) наибольший среди топ-моделей против 0,017–0,024 у логистических

регрессий — сеть не столько хуже в среднем, сколько нестабильнее, что и есть проявление высокого variance.

8.2. Вклад отдельных этапов работы

Этап	Вклад в качество	Комментарий
Feature engineering	от $-0,005$ до $-0,021$	Отрицательный, но в пределах шума. Полезным оказался только <code>st_burden</code> , выражающий взаимодействие.
Подбор гиперпараметров	$0,002$ (до $+0,029$ у других семейств)	В пределах разброса по фолдам; вложенная CV выявила смещение $+0,011$ → «У победившей модели — в пределах разброса по фолдам; вложенная CV выявила смещение $+0,011$.
Нейронная сеть	$-0,014$ относительно лучшей	13-е место из 28 при наибольшем разбросе по фолдам.
Ансамблирование	$-0,003$ по AUC, $+0,03$ по log-loss	Выигрыш только в калибровке вероятностей.
Выбор порога	наибольший практический эффект	Не меняет ROC-AUC, но сокращает число пропущенных больных с трёх до нуля.

Таблица 7. Вклад этапов исследования в итоговое качество

Последняя строка содержит главный практический вывод работы: борьба за третий знак ROC-AUC дала меньше, чем одно решение о том, где поставить порог классификации.

8.3. Ограничения и направления дальнейшей работы

- Размер выборки. 303 пациента — доверительные интервалы всех метрик широки, различия в сотых долях ROC-AUC лежат внутри шума.
- Репрезентативность. Данные собраны в одной клинике (Cleveland Clinic, 1980-е годы, преимущественно белое население США). Проверка по подгруппам не выявила драматического расслоения качества (ROC-AUC 1,000 у женщин при $n = 20$ и 0,936 у мужчин при $n = 41$), однако при таких объёмах подгрупп эти оценки имеют широкие доверительные интервалы и вывод о переносимости модели на другие популяции сделать нельзя.
- Признаки `sa` и `thal` получены дорогими процедурами: модель без них слабее на 0,056 ROC-AUC, но представляет отдельный сценарий применения. Соотношение цен ошибок 10 : 1 является экспертной оценкой и требует уточнения совместно с клиницистами.
- Внешняя валидация на данных другой клиники — единственный способ проверить переносимость модели.
- Расширение выборки. Кривые обучения по объёму данных показывают, что валидационное качество перестаёт заметно расти уже к 80–100

объектам, но остаётся примерно на 0,08 ниже обучающего: сохраняющийся разрыв указывает, что дополнительные данные принесут больше, чем дальнейшее усложнение моделей.

- Калибровка вероятностей (Platt scaling, изотоническая регрессия) и проспективная оценка: как решения модели влияют на клинический исход, а не только совпадают ли с ретроспективным диагнозом.

Состав работы: Jupyter Notebook (119 ячеек, из них 74 кодовые, выполнены последовательно без ошибок), настоящий отчёт, репозиторий на GitHub с README и requirements.txt. Программные средства: Python 3, scikit-learn, PyTorch, XGBoost, LightGBM, CatBoost, SHAP, SciPy, pandas, matplotlib, seaborn. Полное время выполнения — около пяти минут на CPU.